Trabajo Práctico 1: UdeSA Panorámica

García, González y Turkie
I308 - Visión Artificial - Universidad de San Andrés

16 de septiembre de 2026

1. Introducción

Este trabajo une tres fotografías con solapamiento parcial en una única imagen panorámica sin costuras visibles. El procedimiento consta de cuatro pasos: detectar características visuales locales, emparejarlas entre pares de imágenes, estimar la homografía que relaciona cada par, y deformar y mezclar las imágenes sobre un lienzo común.

Desarrollamos el método sobre el conjunto *Cuadro* y después probamos el resultado sobre otros dos, el conjunto *UdeSA*, también provisto por la cátedra, y uno propio que tomamos nosotros. Salvo donde se indique lo contrario, las figuras, tablas y métricas corresponden al conjunto *Cuadro* y están expresadas en píxeles de las imágenes reducidas al 25 %. La detección y descripción de características usa SIFT de OpenCV y el warping final usa `warpPerspective`. A-NMS, DLT, RANSAC, el cálculo del tamaño del lienzo y el blending están implementados por nosotros con NumPy.

2. Fundamentos geométricos

2.1. Por qué una homografía

Una homografía es una transformación proyectiva del plano, $\mathbf{x}' \sim H\mathbf{x}$ en coordenadas homogéneas, con H una matriz de 3×3 definida a menos de un factor de escala y, por lo tanto, con 8 grados de libertad. Transforma rectas en rectas, aunque no conserva el paralelismo. La primera propiedad nos permite calcular el tamaño del lienzo a partir de las esquinas y la segunda produce el efecto de perspectiva en las imágenes deformadas.

Que la relación entre dos fotografías se pueda escribir con una única homografía no es automático. Al proyectar se pierde la profundidad, porque un píxel no determina un punto del espacio sino toda una recta de puntos que caen sobre él. Al cambiar el punto de vista, dónde aparece cada uno de esos puntos en la imagen depende de qué tan lejos estaba, así que en general no existe una transformación del plano que sirva para toda la escena.

Hay dos situaciones en las que la profundidad deja de importar. La primera es que **la escena sea plana**. Todos sus puntos están a la profundidad que les impone el plano, y entonces una homografía relaciona las dos vistas de ese plano para cualquier movimiento de la cámara, aunque solo para los puntos del plano. La segunda es que **la cámara solo rote sobre su centro óptico**. Las dos vistas comparten el centro de proyección, así que los puntos de una misma recta visual siguen cayendo juntos en la segunda imagen sin importar su profundidad, y la relación vale para toda la escena.

2.2. Hipótesis y qué pasa si no se cumplen

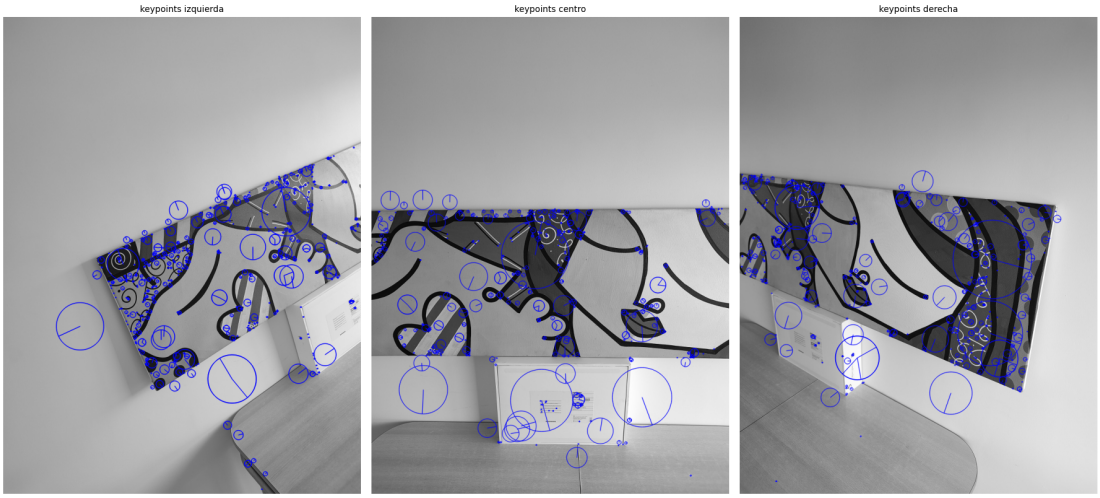
El modelo requiere entonces que la escena sea plana o que la cámara solo rote sobre su centro óptico, y además que la escena esté estática y que la cámara no introduzca una distorsión de lente apreciable.

Cuando ninguna de las dos primeras condiciones se cumple aparece paralaje. Al mover la cámara, los objetos cercanos se desplazan más entre una toma y otra que los lejanos. Una homografía asigna un único desplazamiento a cada posición de la imagen, así que no puede alinear a la vez objetos a distintas profundidades. Los que quedan fuera del plano elegido aparecen duplicados o desalineados en la zona de solapamiento.

2.3. Análisis de los conjuntos provistos

En el conjunto *Cuadro* la pintura es plana, así que se cumple la primera condición *para los puntos de la pintura*. La cámara además se trasladó entre fotografías. En las imágenes laterales se ve una cara lateral de la caja apoyada sobre la mesa que la imagen central no muestra, y con rotación pura nunca aparecen caras nuevas de un objeto ni cambian las oclusiones. La caja y la mesa están a una profundidad distinta de la pintura, así que esperamos que queden desalineadas en el resultado. Sus correspondencias, aunque sean correctas, no cumplen la homografía del plano de la pintura, y RANSAC las clasifica como outliers.

En el conjunto *UdeSA* las tomas corresponden a un paneo sobre una escena lejana. Al estar todo lejos, el desplazamiento por paralaje es despreciable aunque el fotógrafo se haya movido unos centímetros, y la aproximación de rotación pura resulta razonable para los edificios del fondo. El riesgo se concentra en el pasto y los árboles del primer plano.



(a) Detecciones de SIFT.



(b) Selección de A-NMS con $N = 400$.

Figura 1: Características visuales en el conjunto *Cuadro*, reducido al 25 %. El radio de cada círculo es proporcional a la escala del keypoint y el segmento indica su orientación. La pared lisa no genera detecciones por el criterio de bajo contraste y el borde recto del marco genera pocas por el criterio de bordes. Tras A-NMS la densidad se reparte de manera más uniforme y los grupos superpuestos en las espirales y en el patrón de lunares quedan reducidos.

3. Método

3.1. Detección y descripción de características

Usamos SIFT porque la relación entre las tomas incluye rotación y cambio de escala, y es invariante a ambas. Su descriptor concatena los histogramas de gradientes normalizados de 4×4 subregiones con 8 orientaciones cada una, de donde salen las 128 dimensiones. La normalización le da invariancia parcial a los cambios de iluminación, y la comparación entre descriptores se hace con distancia euclídea.

Antes de detectar reducimos las imágenes al 25 % con `INTER_AREA`. A resolución completa SIFT devuelve 13.707, 15.252 y 14.062 keypoints en las tres imágenes, de los cuales más del 92 % mide menos de 4 píxeles, detalles finos y ruido de compresión JPEG que no se repiten entre tomas. Al reducir quedan 494, 430 y 504, más estables (Figura 1a). El costo también baja. A-NMS compara cada keypoint contra todos los demás, así que con 14.000 keypoints son unos 200 millones de comparaciones por imagen y con 500 apenas 250.000.

3.2. Supresión de no máxima adaptativa

SIFT concentra sus detecciones donde hay más textura, y una homografía estimada con puntos amontonados en una región extrapola mal al resto de la imagen. A-NMS asigna a cada keypoint k_i un radio de supresión

$$R_i = \min_{j\,:\,r_j > r_i} \left[(x_j - x_i)^2 + (y_j - y_i)^2 \right], \qquad (1)$$

es decir, la distancia al keypoint más cercano que tenga mayor respuesta r, y conserva los N de mayor radio. Un keypoint con radio grande domina una región amplia. Uno con radio chico tiene un vecino más fuerte al lado y es redundante. El máximo global no tiene ningún punto más fuerte, su radio queda en infinito y siempre sobrevive.

Tomamos tres decisiones al implementarlo. El conjunto de máximos locales de entrada es el conjunto completo de keypoints de SIFT, porque ya son extremos locales en el espacio de escalas de la diferencia de gaussianas. La actualización del radio se ejecuta dentro de la condición $r_j > r_i$, a diferencia del pseudocódigo del enunciado, donde la comparación queda fuera del `if` y arrastra valores de iteraciones anteriores. Por último, trabajamos con la distancia al cuadrado, que ordena igual que la distancia y evita calcular raíces.

Fijamos $N = 400$ (Figura 1b). Valores más chicos empeoran el matching. Como A-NMS se aplica por separado en cada imagen, una correspondencia sobrevive solo si sus dos extremos son seleccionados, y la probabilidad de que eso ocurra cae aproximadamente con el cuadrado de la fracción conservada.

3.3. Asociación de características

El matching se hace de a pares contra la imagen central, que actúa como ancla, izquierda con centro y derecha con centro. Para cada descriptor del ancla buscamos sus dos vecinos más cercanos entre los descriptores de la lateral, por fuerza bruta con `BFMatcher` y norma L2. Con 400 descriptores por imagen, las 160.000 distancias de cada par se calculan en forma exacta y en tiempo despreciable, así que no recurrimos a la búsqueda aproximada de FLANN.

El vecino más cercano existe siempre, incluso para puntos que no aparecen en la otra imagen, de modo que hay que filtrar. Comparamos dos criterios.

El **ratio de Lowe** conserva un match cuando $d_1 < \rho\, d_2$, con d_1 y d_2 las distancias al primer y al segundo vecino. Un umbral absoluto sobre d_1 no sirve porque la escala de las distancias depende de cuán distintiva sea cada zona de la imagen, y el segundo vecino estima cuán lejos están los descriptores no relacionados en esa misma zona. Si d_1 no es mucho menor que d_2, el descriptor no distingue entre dos candidatos y el match se descarta.

La **verificación cruzada** conserva los pares que son vecinos mutuos. Elimina los casos en que varios descriptores del ancla eligen el mismo descriptor de la lateral, pero no detecta la ambigüedad, porque en un patrón repetido dos franjas equivocadas pueden ser vecinas mutuas.

Los dos criterios atacan problemas distintos, así que los combinamos. Aplicamos el ratio de Lowe y nos quedamos con los pares que además aparecen en el resultado con verificación cruzada. Como `BFMatcher` no admite `crossCheck` junto con la búsqueda de dos vecinos, calculamos ambos conjuntos por separado y los intersecamos comparando los índices `(queryIdx, trainIdx)` de cada match. La Tabla 1 muestra cuántas correspondencias deja cada política y la Figura 2 el resultado sobre el par izquierdo.

Elegimos $\rho = 0{,}8$ a partir de la Tabla 1. Los umbrales más estrictos dejan muy pocas correspondencias en el par derecho, y con diez pares la homografía se vuelve inestable. El par derecho produce sistemáticamente menos matches que el izquierdo porque esa toma tiene mayor cambio de punto de vista, y SIFT es solo parcialmente invariante a deformaciones afines.

Cuadro 1: Correspondencias que sobreviven a cada política de filtrado, sobre 400 keypoints por imagen. C es la imagen central.

Política	C–Izq.	C–Der.
Sin filtrar	400	400
Verificación cruzada	174	148
Lowe $\rho = 0{,}5$	42	10
Lowe $\rho = 0{,}6$	63	19
Lowe $\rho = 0{,}7$	88	41
Lowe $\rho = 0{,}8$	123	81
Lowe 0,8 + cruzada	**94**	**59**

3.4. Estimación manual de la homografía por DLT

Para cada par elegimos manualmente cuatro correspondencias y estimamos H con el algoritmo DLT. Escribiendo $\mathbf{x}' \sim H\mathbf{x}$ en coordenadas inhomogéneas,

$$x' = \frac{h_{11}x + h_{12}y + h_{13}}{h_{31}x + h_{32}y + h_{33}}, \quad y' = \frac{h_{21}x + h_{22}y + h_{23}}{h_{31}x + h_{32}y + h_{33}}, \tag{2}$$

y multiplicando por el denominador, cada correspondencia aporta dos ecuaciones lineales en los elementos de H:

$$\begin{bmatrix} x & y & 1 & 0 & 0 & 0 & -x'x & -x'y & -x' \\ 0 & 0 & 0 & x & y & 1 & -y'x & -y'y & -y' \end{bmatrix} \mathbf{h} = \mathbf{0}. \tag{3}$$

Como H tiene 8 grados de libertad, cuatro correspondencias alcanzan para determinarla. Acá resolvemos la variante inhomogénea, donde fijando $h_{33} = 1$ quedan ocho incógnitas y el sistema se vuelve cuadrado de 8×8. En la Sección 3.5 usamos la formulación homogénea, que admite cualquier cantidad de puntos.

La elección de los cuatro pares condiciona el resultado. Los puntos tienen que pertenecer al plano que se quiere alinear, en este caso la pintura y no la caja ni la mesa. No puede haber tres puntos alineados, porque una homografía preserva las rectas y la matriz del sistema pierde rango. Y conviene que formen un cuadrilátero lo más grande posible dentro de la zona de solapamiento. Con los puntos concentrados, el error de un píxel al marcarlos se amplifica lejos de ellos, que es justamente donde la homografía se usa al deformar la imagen completa.

3.5. RANSAC

RANSAC automatiza y robustece esa estimación. En cada iteración samplea al azar las cuatro correspondencias que necesita el modelo, computa la homografía candidata con DLT, proyecta *todas* las correspondencias del par y cuenta cuántos inliers tiene, es decir cuántas caen a menos de un umbral de tolerancia t de su destino medido. Se queda con el conjunto de inliers

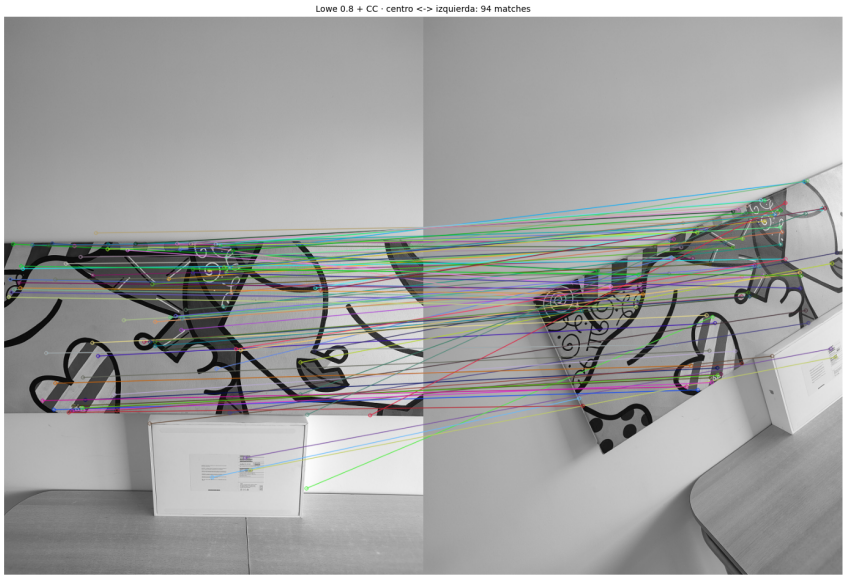


Figura 2: Correspondencias entre la imagen central y la izquierda con el ratio de Lowe y verificación cruzada. Quedan 94 de las 400 iniciales y la mayoría de las líneas cruzadas desaparecen, aunque sobreviven algunas sobre la caja y la mesa.

más numeroso. Si las cuatro muestras son inliers, la homografía resultante es aproximadamente correcta y el resto de los inliers la acompaña. Si alguna es un outlier, la homografía se deforma y casi ninguna correspondencia la respalda.

Fijamos $t = 3$ píxeles. El umbral tiene que ser mayor que el error con el que SIFT localiza un keypoint, del orden del píxel, para no descartar correspondencias correctas, y bastante menor que el desplazamiento de los outliers para que RANSAC los separe.

La cantidad de intentos T se calcula a partir del ratio de outliers e y del tamaño de la muestra s, que para una homografía es 4. La probabilidad de que los s puntos sampleados sean todos inliers es $(1-e)^s$, la de que la muestra falle es $1-(1-e)^s$, y la de que fallen las T iteraciones es $(1-(1-e)^s)^T$. Pidiendo una probabilidad de éxito p y despejando,

$$T = \frac{\log(1-p)}{\log\left(1-(1-e)^s\right)}. \tag{4}$$

Con los ratios de outliers que medimos ($e \approx 0{,}46$ en el par izquierdo y $e \approx 0{,}68$ en el derecho) y $p = 0{,}99$, la Ecuación 4 pide 51 y 426 iteraciones. Usamos $T = 2000$, que deja margen suficiente y se ejecuta en menos de un segundo, con semilla fija para que los resultados sean reproducibles.

Cuando una muestra contiene dos keypoints en la misma posición, algo posible porque SIFT genera detecciones repetidas con distinta orientación, el sistema del DLT es singular, así que capturamos la excepción y descartamos esa muestra.

La Figura 3 muestra la clasificación resultante en el par izquierdo. Con el conjunto de inliers ya determinado, recalculamos la homografía final por cuadrados mínimos usando todos ellos. El sistema pasa a tener $2n$ ecuaciones y nueve incógnitas, sin solución exacta por el ruido de localización, así que planteamos el problema de cuadrados mínimos totales

$$\min_{\|\mathbf{h}\|=1} \|A\mathbf{h}\| \tag{5}$$

mediante la descomposición en valores singulares $A = U\Sigma V^T$. Escribiendo $\mathbf{h} = V\mathbf{y}$ con $\|\mathbf{y}\| = 1$ resulta $\|A\mathbf{h}\| = \|\Sigma\mathbf{y}\|$, cuyo mínimo se alcanza concentrando todo el peso en el menor valor singular, de modo que $\mathbf{h}$ es la última fila de V^T. La restricción $\|\mathbf{h}\| = 1$ descarta la solución trivial y fija la escala libre de la homografía. Por último reacomodamos $\mathbf{h}$ como matriz de 3×3 y la dividimos por h_{33}. Estimada con muchos inliers, la homografía promedia el ruido de localización en lugar de copiarlo, como ocurre con cuatro puntos.

Al ciclo le agregamos una ronda más. Recalculamos el conjunto de inliers con esa homografía final y volvemos a ajustar. La clasificación inicial se había hecho con una homografía estimada a partir de solo cuatro puntos, y al mejorarla algunas correspondencias cambian de lado. En nuestros datos el conjunto se estabiliza en una sola ronda.

3.6. Tamaño óptimo de la imagen final

Las homografías llevan cada lateral al sistema de coordenadas de la imagen central, donde parte del contenido cae en coordenadas negativas o más allá del ancho de la central. Para que la panorámica contenga las tres imágenes completas y sin bordes sobrantes, proyectamos las cuatro esquinas de cada imagen con su homografía (la identidad para el ancla) y tomamos los extremos de las doce esquinas resultantes:

$$x_{\min} = \min_{i,k} p^{(i)}_{k,x}, \qquad x_{\max} = \max_{i,k} p^{(i)}_{k,x}, \tag{6}$$

y análogamente en y, redondeando hacia afuera. Alcanza con las esquinas porque una homografía transforma rectas en rectas. El rectángulo de cada imagen se convierte en un cuadrilátero, y los valores extremos de un polígono se alcanzan en sus vértices. La propiedad

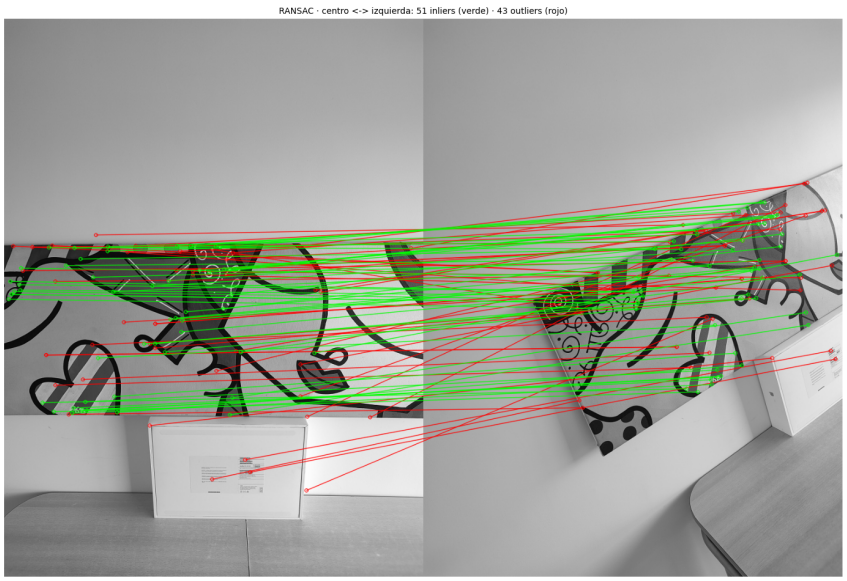


Figura 3: Inliers (verde) y outliers (rojo) hallados por RANSAC en el par centro–izquierda con $t = 3$ píxeles. Las correspondencias descartadas incluyen las que caen sobre la caja y la mesa, que son correctas pero no pertenecen al plano de la pintura.

requiere que la tercera coordenada homogénea no cambie de signo dentro de la imagen, algo que verificamos en las cuatro esquinas de cada una.

El lienzo mide entonces $(x_{\text{máx}} - x_{\text{mín}}) \times (y_{\text{máx}} - y_{\text{mín}})$, y la traslación que lleva $(x_{\text{mín}}, y_{\text{mín}})$ al origen es

$$T = \begin{bmatrix} 1 & 0 & -x_{\text{mín}} \\ 0 & 1 & -y_{\text{mín}} \\ 0 & 0 & 1 \end{bmatrix}. \tag{7}$$

Las transformaciones finales son TH_i para las laterales y T para el ancla. El orden del producto importa, porque TH deforma primero y traslada después. Para el conjunto *Cuadro* el lienzo resultante es de 1544×1645 píxeles, y al reproyectar las doce esquinas con las transformaciones ajustadas los mínimos dan 0 y los máximos coinciden con esas dimensiones.

3.7. Warping y blending

Con `warpPerspective` deformamos cada imagen en color al lienzo usando su transformación ajustada. En las zonas de solapamiento, superponer una imagen sobre otra dejaría un corte visible, agravado por las diferencias de exposición entre tomas. En cambio, calculamos cada píxel del resultado como un promedio ponderado de las imágenes que lo cubren:

$$I = \frac{\sum_i W_i \, I_i}{\sum_i W_i}. \tag{8}$$

Los pesos W_i se construyen con `distanceTransform` sobre una máscara del tamaño de la imagen original con un borde de ceros, lo que da la distancia de cada píxel al borde más cercano, y se deforman al lienzo con la misma homografía que su imagen. Un píxel cercano al borde de una imagen recibe un peso bajo y la otra imagen domina la mezcla, de modo que la transición es gradual. La división por la suma de los pesos mantiene el brillo. La Ecuación 8 se aplica por separado a cada canal de color, en punto flotante, y donde ninguna imagen cubre el lienzo la suma de pesos es cero y el resultado queda en negro.

Cuadro 2: Resultado de RANSAC en los tres conjuntos, con $t = 3$ píxeles. Cada celda indica el par centro–izquierda y el par centro–derecha.

Conjunto	Matches	Inliers	RMSE (px)
Cuadro	94 / 59	51 / 19	1,46 / 1,52
UdeSA	106 / 46	97 / 30	0,73 / 0,85
Propio	92 / 50	38 / 14	0,73 / 0,58

4. Resultados

4.1. Conjunto Cuadro

La Tabla 2 resume la estimación robusta de las dos homografías, con el error de reproyección calculado como la raíz del error cuadrático medio sobre los inliers de la homografía final.

Los dos errores quedan por debajo de dos píxeles, consistentes con el ruido de localización de SIFT, y la proporción de inliers es menor en el par derecho, donde hay más cambio de perspectiva y más correspondencias sobre la caja y la mesa. El RMSE está acotado por el umbral t por construcción, así que bajar t siempre lo reduce. Por eso lo reportamos junto con la cantidad de inliers.

En la panorámica final (Figura 4a) la pintura se ve continua, y la caja y la mesa muestran el paralaje descrito en la Sección 2.3.



(a) *Cuadro*, escena plana con cámara desplazada.



(b) *UdeSA*, paneo sobre una escena lejana.



(c) Propio, objetos cercanos y cámara desplazada.

Figura 4: Panorámicas de los tres conjuntos, obtenidas con los mismos parámetros. En *Cuadro* la pintura se une sin costuras y la caja queda desalineada, en *UdeSA* no hay objetos duplicados y en el conjunto propio se ven duplicadas la vitrina y las sillas, los objetos más cercanos a la cámara. Las esquinas negras son las zonas del lienzo rectangular que ninguna imagen cubre.

4.2. Comparación entre DLT manual y RANSAC

Comparamos las dos estimaciones proyectando todas las correspondencias del par con cada homografía. Contamos cuántas caen a menos de tres píxeles de su destino medido y calculamos el RMSE de ambas sobre los inliers hallados por RANSAC (Tabla 3).

En el par derecho las dos son comparables, porque la manual alcanza 17 correspondencias en consenso contra 19 de RANSAC, con el doble de error. En el par izquierdo la manual falla por completo porque elegimos mal los cuatro pares. Uno era una correspondencia incorrecta y otros tres quedaron casi alineados. RANSAC hace esa elección solo y se queda con la combinación que más correspondencias respalda.

4.3. Conjunto UdeSA y conjunto propio

Con el método ya ajustado sobre el conjunto *Cuadro*, lo aplicamos a los otros dos sin cambiar ningún parámetro (Figura 4).

El conjunto *UdeSA*, de 3000×3000 píxeles por imagen, es el caso más favorable. El par izquierdo llega al 92 % de inliers y el resultado no muestra costuras ni objetos duplicados, tal como anticipaba la Sección 2.3 para un paneo sobre una escena lejana.

Para el conjunto propio tomamos tres fotografías de 4284×5712 píxeles del interior de un local, barriendo de izquierda a derecha con un solapamiento aproximado del 35 %. Los errores de reproyección son los más bajos de los tres conjuntos y aun así el resultado visual es el peor, porque la vitrina y las sillas aparecen duplicadas en las zonas de solapamiento. La escena combina objetos a muy distinta profundidad, la vitrina a un par de metros y la pared del fondo a más de diez, y además nos desplazamos entre tomas, así que ninguna homografía puede alinearlos a todos. El caso muestra por qué el RMSE sobre los inliers no alcanza como medida de calidad. Mide cuán bien se ajusta el plano dominante y no cuánto del resto de la escena queda desalineado.

Cuadro 3: Homografía manual (cuatro pares) contra RANSAC, en píxeles.

	Consenso		RMSE (px)	
Par	Man.	RANSAC	Man.	RANSAC
C–Izq.	4/94	51/94	4234	1,46
C–Der.	17/59	19/59	2,86	1,52

5. Discusión y limitaciones

El paralaje de la caja y la mesa en el conjunto *Cuadro*, y el de la vitrina en el propio, son la consecuencia directa del análisis de la Sección 2.3. La homografía alinea un plano y ningún otro, y el efecto no se corrige ajustando parámetros porque proviene del modelo geométrico. Los filtros del matching también tienen su costo. El ratio de Lowe descarta correspondencias correctas donde el entorno del keypoint se repite, como en las franjas y en el patrón de lunares del cuadro, y A-NMS a veces conserva un extremo de una correspondencia válida y descarta el otro, razón por la que $N = 400$ funciona mejor que valores más agresivos. El par derecho del conjunto *Cuadro* concentra las limitaciones porque es la toma con mayor cambio de punto de vista y la invariancia de SIFT a deformaciones afines es solo parcial.

6. Conclusiones

El pipeline produce panorámicas sin costuras visibles sobre el plano dominante de la escena, con errores de reproyección menores a dos píxeles en los tres conjuntos. Lo que más pesó en la calidad fue la cantidad de correspondencias correctas disponibles. Lo que no alinea son los objetos fuera del plano elegido, un límite del modelo y no del ajuste.